

# Métodos Estocásticos da Engenharia II

## Capítulo 3 - Distribuições Amostrais e Estimação Pontual de Parâmetros

Prof. Magno Silvério Campos

2024/2



# Bibliografia

Essas notas de aulas foram baseadas nas seguintes obras:

- ❶ CANCHO, V.G. *Notas de Aulas sobre Noções de Estatística e Probabilidade*. São Paulo: USP, 2010.
- ❷ HINES, W.W.; et al. *Probabilidade e Estatística na Engenharia*. 4. ed. Rio de Janeiro: LTC, 2006.
- ❸ MONTGOMERY, D.C.; RUNGER, G.C. *Estatística Aplicada e Probabilidade para Engenheiros*. 6. ed. Rio de Janeiro: LTC, 2016.

Aconselha-se pesquisá-las para se obter um **maior aprofundamento** e um **melhor aproveitamento** nos estudos.



# Conteúdo Programático

- ❶ Seção 1 - Introdução
- ❷ Seção 2 - Conceitos gerais de estimação pontual
- ❸ Seção 3 - Método da Máxima Verossimilhança
- ❹ Seção 4 - Distribuições amostrais
  - Distribuição da média amostral;
  - Teorema do Limite Central;
  - Distribuição da diferença de duas médias amostrais;
  - Distribuição amostral de uma proporção amostral.
- ❺ Seção 5\* - Outras distribuições utilizadas na inferência estatística
  - Distribuição Qui-quadrado;
  - Distribuição t-Student;
  - Distribuição F-Snedecor;



# Introdução

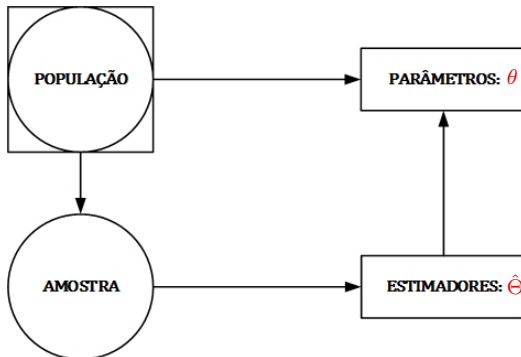
## Amostra

Se uma população for numerosa, talvez não seja possível estudar cada um dos seus elementos. Portanto, é muito difícil ter uma informação completa sobre ela. Nesses casos, recorre-se à informação proporcionada por uma parte finita da população, denominada **amostra**.

Uma **amostra aleatória** tem a propriedade de refletir as características da população da qual foi sorteada.



## Esquema geral



## Amostra aleatória - [Montgomery e Runger(2016)]

As variáveis aleatórias  $X_1, X_2, \dots, X_n$  constituem uma amostra aleatória de tamanho  $n$  de uma população  $X \sim f(x, \theta)$ , se: (a) cada  $X_i$  é uma variável aleatória independente e (b) cada  $X_i$  tem a mesma distribuição de probabilidade  $f(x, \theta)$ .



## Amostra aleatória- [Cancho(2010)]

A definição de amostra aleatória é satisfeita nos seguintes casos:

- 1 Quando a amostra provem de uma população infinita e quando a amostra é sorteada ao acaso com reposição de uma população finita.
- 2 Quando se sorteia a amostra sem reposição de uma população finita, evidentemente não se satisfaz a definição de amostra aleatória, pois as variáveis aleatórias  $X_1, \dots, X_n$  não são independentes. Porém, se o tamanho da amostra é muito pequeno em comparação com o tamanho da população, a definição é satisfeita aproximadamente.



## Estimadores pontuais - ([Montgomery e Runger(2016)])

Em geral, se  $X$  for uma variável aleatória com distribuição de probabilidades  $f(x)$ , caracterizada por um parâmetro desconhecido  $\theta$ , e se  $X_1, X_2, \dots, X_n$  for uma amostra aleatória de tamanho  $n$ , então a estatística  $\hat{\Theta} = h(X_1, X_2, \dots, X_n)$  é chamada de um **estimador pontual** de  $\theta$ .

Note que:

$\hat{\Theta}$  é uma variável aleatória, porque ela é função de variáveis aleatórias.

## Exemplo - ([Montgomery e Runger(2016)])

Suponha que a variável aleatória  $X$  seja normalmente distribuída, com uma média desconhecida  $\mu$ . A média da amostra é um estimador da média desconhecida  $\mu$  da população. Isto é,

$$\hat{\mu} = \bar{X}$$



## Estimativas pontuais

Depois da amostra ter sido escolhida,  $\hat{\Theta}$  assume um valor numérico  $\hat{\theta}$ , denominado **estimativa pontual** de  $\theta$ .

### Exemplo

No exemplo anterior, depois da amostra ter sido escolhida, o valor numérico  $\bar{x}$  é a estimativa pontual de  $\mu$ . Assim, se  $x_1 = 30, x_2 = 20, x_3 = 15, x_4 = 40$  e  $X_5 = 25$ , então a estimativa de  $\mu$  é

$$\bar{x} = \frac{30+20+15+40+25}{5} = 26$$



Analogamente, se a variância da população  $\sigma^2$  for também desconhecida, um **estimador pontual** para  $\sigma^2$  será a variância da amostra  $S^2$  e o valor numérico deste, calculado a partir dos dados da amostra, é chamado de **estimativa pontual** de  $\sigma^2$ .



# Problemas de estimação frequentes em engenharia

## Geralmente, necessitamos estimar:

- a média  $\mu$  de uma população;
- a variância  $\sigma^2$  de uma população;
- a proporção  $p$  de itens em uma população que pertencem a uma classe de interesse;
- a diferença nas médias de duas populações,  $\mu_1 - \mu_2$ ;
- a diferença nas proporções de duas populações,  $p_1 - p_2$ ;
- entre outros.

## Estimativas pontuais razoáveis:

- Para  $\mu$ , a estimativa é  $\hat{\mu} = \bar{x}$ , a média da amostra;
- Para  $\sigma^2$ , a estimativa é  $\hat{\sigma}^2 = s^2$ , a variância da amostra;
- Para  $p$ , a estimativa é  $\hat{p} = x/n$ , a proporção da amostra;
- Para  $\mu_1 - \mu_2$ , a estimativa é  $\hat{\mu}_1 - \hat{\mu}_2 = \bar{x}_1 - \bar{x}_2$ , a diferença entre as médias de duas AAI;
- Para  $p_1 - p_2$ , a estimativa é  $\hat{p}_1 - \hat{p}_2$ , a diferença entre as proporções de duas AAI.

# Conceitos gerais de estimação pontual

## [1] - Tendência de um estimador

O estimador  $\hat{\Theta}$  é um estimador **não-tendencioso** para o parâmetro  $\theta$ , se

$$E(\hat{\Theta}) = \theta$$


Se o estimador for tendencioso, então a **tendência** é dada por:

$$E(\hat{\Theta}) - \theta.$$

**Exemplo:** mostrar que a média amostral  $\bar{X}$  é um estimador não tendencioso da média populacional,  $\mu$ .

## [2] - Variância de um estimador

Embora possam existir muitos estimadores  $\hat{\theta}$  não tendenciosos para o parâmetro  $\theta$ , deve-se escolher aquele que tiver variância mínima, isto é, o **Estimador Não Tendencioso de Variância Mínima (ENTVM)** é o mais provável de produzir uma estimativa mais próxima do valor verdadeiro de  $\theta$ .



**Exemplo:** considere dois estimadores para a média populacional,  $\mu$ : a média amostral,  $\bar{X}$ , e uma única observação,  $X_i$ , proveniente da amostra. Neste caso, qual dos dois é melhor?



### [3] - Erro-padrão de um estimador

O erro-padrão de um estimador  $\hat{\Theta}$  é o seu **desvio-padrão**, isto é,

$$\sigma_{\hat{\Theta}} = \sqrt{V(\hat{\Theta})}.$$

Essa é uma medida de precisão da estimação muito útil. Caso sejam utilizadas estimativas amostrais, a notação muda para  $\hat{\sigma}_{\hat{\Theta}} = SE(\hat{\Theta})$ .

**Exemplo:** considere uma amostra aleatória proveniente de uma população normal com média  $\mu$  e variância  $\sigma^2$ . Determine o erro-padrão da média amostral,  $\bar{X}$ , para os casos de variância  $\sigma^2$  conhecida ou desconhecida.



## Método da Máxima Verossimilhança

Existem alguns métodos de estimação pontual conhecidos na literatura estatística. Um dos melhores métodos para obter estimadores pontuais de parâmetros populacionais é o **Método da Máxima Verossimilhança**, que veremos a seguir.

Seja  $X$  uma variável aleatória que segue uma distribuição de probabilidades  $f(x, \Theta)$ , onde  $\Theta$  é um vetor de parâmetros  $\theta$  desconhecidos.

Sejam  $x_1, x_2, \dots, x_n$  os valores observados em uma amostra aleatória de tamanho  $n$ . A **função de verossimilhança** da amostra é definida como:

$$L(\Theta) = f(x_1, \Theta) \cdot f(x_2, \Theta) \cdot \dots \cdot f(x_n, \Theta).$$

A função acima informa sobre a possibilidade (verossimilhança) de a variável  $X$  assumir os valores  $x_1, x_2, \dots, x_n$ ; Para o caso de VAD, a verossimilhança é um valor de probabilidade.

A função de verossimilhança é função apenas do parâmetro desconhecido  $\Theta$ . O **Estimador de Máxima Verossimilhança (EMV)** de  $\Theta$  é o valor de  $\Theta$  que maximiza  $L(\Theta)$ . Tal valor é obtido derivando  $L(\Theta)$  em relação a  $\Theta$  e igualando o resultado a 0.

**Fato:**  $L(\Theta)$  e  $\ln L(\Theta)$  apresentam seus máximos no mesmo valor de  $\Theta$ . Assim,

$$\frac{\partial L(\Theta)}{\partial \Theta} = 0 \quad \Rightarrow \quad \frac{\partial \ln L(\Theta)}{\partial \Theta} = 0$$

O Estimador de Máxima Verossimilhança ( $\hat{\Theta}$ ) apresenta, em geral, propriedades assintóticas favoráveis:

- $\hat{\Theta}$  é não tendencioso para valores grandes de  $n$ ;
- $\hat{\Theta}$  apresenta uma variância tão pequena quanto possível de ser obtida com qualquer outro estimador;
- $\hat{\Theta}$  tem distribuição aproximadamente normal.



**Exemplo 1** - [Montgomery e Runger(2016)]

Tempos até a falha de certo equipamento eletrônico seguem uma distribuição exponencial com parâmetro  $\lambda$  e  $fdp$  dada por:

$$f(x, \lambda) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases} \quad (1)$$

Obtenha o estimador de máxima verossimilhança de  $\lambda$ .





**Exercício** - [Montgomery e Runger(2016)]

Tempos até a falha de certo equipamento eletrônico seguem uma distribuição exponencial. Alguns destes tempos foram anotados de forma contínua, obtendo-se os seguintes valores:

48; 80; 122; 188; 189; 220; 253; 311; 325; 358; 490; 495; 513; 723; 773;  
879; 1510; 1674; 1809; 2005; 2028; 2038; 2870; 3103; 3205.

Determine a estimativa de  $\lambda$  de acordo com o método da máxima verossimilhança.





**Exemplo 2** - [Montgomery e Runger(2016)]

Considere uma variável aleatória normalmente distribuída, com parâmetros  $\mu$  e  $\sigma^2$  desconhecidos, com  $f_{dp}$  dada por:

$$f(x, \mu, \sigma^2) = \frac{1}{\sigma\sqrt{2\pi}} e^{-(x-\mu)^2/(2\sigma^2)}, \quad -\infty < x < \infty. \quad (2)$$

Obtenha os estimadores de máxima verossimilhança para  $\mu$  e  $\sigma^2$ .





### Observação 1:

Para utilizar a estimação pelo Método da Máxima Verossimilhança, é necessário o conhecimento da distribuição de probabilidades da população.

### Observação 2:

Complicações podem surgir na obtenção do máximo da função de verossimilhança, tornando necessário o emprego de métodos computacionais avançados.



# Distribuição da média amostral

Se de uma população com média  $\mu_X$  e variância  $\sigma_X^2$  se extraem amostras aleatórias de tamanho  $n$  e para cada amostra determina-se a média

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i,$$

então a média e variância da variável  $\bar{X}$  são dadas por:





- a) Se a amostragem é com reposição de uma população finita (ou amostragem com ou sem reposição em uma população infinita).

$$\mu_{\bar{X}} = \mu_X \quad e \quad \sigma_{\bar{X}}^2 = \frac{\sigma_X^2}{n}$$

- b) Se a amostragem é sem reposição de uma população finita com  $N$  elementos.

$$\mu_{\bar{X}} = \mu_X \quad e \quad \sigma_{\bar{X}}^2 = \frac{\sigma_X^2}{n} \left[ \frac{N-n}{N-1} \right]$$

### Observação

Se a fração de amostragem  $f = \frac{n}{N}$  é pequena ( $f < 0,1$ ) e o tamanho da população ( $N$ ) é grande, a variância da média amostral em (b) é aproximada com a expressão do caso (a), isto é,

$$\sigma_{\bar{X}}^2 = \frac{\sigma_X^2}{n}$$

## Exemplo

Considere os seguintes níveis  $X$  de estoque para 4 produtos em um determinado dia:

<i>Produto</i>	A	B	C	D
$X$	0	2	0	1

Obter a média e a variância da média amostral para amostragem com ou sem reposição, quando  $n = 2$ .







## Forma da distribuição da média amostral quando a população é normal

Seja  $X$  uma variável aleatória que tem uma distribuição normal com média  $\mu_X$  e variância  $\sigma_X^2$ . Se desta distribuição selecionam-se amostras aleatórias de tamanho  $n$ , a média amostral,

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i,$$

é uma combinação linear de variáveis  $X_i$ , todas elas com distribuição  $N(\mu_X, \sigma_X^2)$  e independentes entre si (o fato da distribuição de  $X$  ser normal presume, em rigor que a população é infinita e que, portanto, não há diferença entre escolher uma amostra com e sem reposição [Cancho(2010)]).



Vale lembrar que:

### Combinação linear de variáveis aleatórias normais

Sejam  $X_1, \dots, X_n$ ,  $n$  variáveis aleatórias independentes onde  $X_i \sim N(\mu_i; \sigma_i^2)$  para  $i = 1, \dots, n$  e sejam  $a_1, \dots, a_n$  constantes reais. Seja a variável aleatória  $Y$  uma combinação linear das variáveis aleatórias normais,  $X_1, \dots, X_n$ . Isto é,

$$Y = a_1 X_1 + a_2 X_2 + \dots + a_n X_n.$$

Então a variável aleatória  $Y$  tem distribuição normal com média

$$\mu_Y = a_1 \mu_1 + a_2 \mu_2 \dots + a_n \mu_n = \sum_{i=1}^n a_i \mu_i$$

e variância

$$\sigma_Y^2 = a_1^2 \sigma_1^2 + a_2^2 \sigma_2^2 \dots + a_n^2 \sigma_n^2 = \sum_{i=1}^n a_i^2 \sigma_i^2.$$

Ou seja:

Uma combinação linear de variáveis normais independentes também é normal!

Portanto,

a média amostral segue uma distribuição normal com média  $\mu_X$  e variância,  $\frac{\sigma_X^2}{n}$ . Isto é,

$$\bar{X} \sim N(\mu_X, \sigma_X^2/n).$$

Embora este resultado seja de extrema importância, ele é relativamente limitado, já que, somente permite especificar a distribuição da média amostral no caso de uma população normal.



## Forma da distribuição da média amostral quando a população é normal

**Exemplo** - [Montgomery e Runger(2016)]

Uma empresa fabrica resistores que têm uma resistência média de 100 ohms e um desvio-padrão de 10 ohms. A distribuição de resistência é **normal**. Encontre a probabilidade de uma amostra aleatória de  $n = 25$  resistores ter uma **resistência média** menor que 95 ohms.



# Forma da distribuição da média amostral quando a população não é normal

## Observação 1

Muitas vezes não temos informação a respeito da distribuição das variáveis que constituem a amostra, fato que nos impede de utilizar o resultado apresentado.

## Observação 2

Felizmente, satisfeitas certas condições, pode ser mostrado que para uma amostra suficientemente grande, a distribuição de probabilidade da média amostral pode ser **aproximada por uma distribuição normal**, com média e variância iguais àquelas calculadas anteriormente. Este fato é um dos teoremas mais importantes da estatística e probabilidade e é denominado o **Teorema do Limite Central** [Montgomery e Runger(2016)].

# Forma da distribuição da média amostral quando a população não é normal

## Teorema do Limite Central

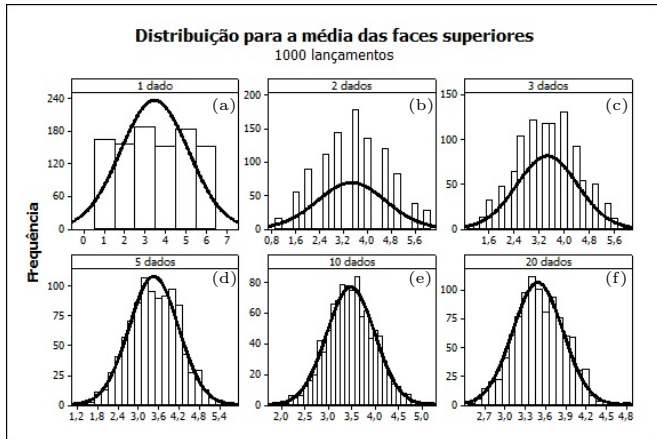
Se  $X_1, X_2, \dots, X_n$  for uma amostra aleatória de tamanho  $n$ , retirada de uma população (finita ou infinita), com média  $\mu$  e variância  $\sigma^2$ , e se  $\bar{X}$  for a média da amostra, então  $\bar{X}$  tem distribuição aproximadamente normal com média  $\mu_X$  e variância  $\sigma_X^2/n$ , para  $n$  suficientemente grande ( $n \rightarrow \infty$ ). Isto é,

$$Z = \frac{\bar{X} - \mu_X}{\sigma_X/\sqrt{n}} \xrightarrow{n \rightarrow \infty} N(0, 1).$$



## Teorema do Limite Central

A aproximação normal para  $\bar{X}$  depende do tamanho  $n$  da amostra. A figura a seguir mostra a distribuição obtida para 1000 arremessos de dados:



- as figuras de (a) a (f) mostram, respectivamente, a distribuição das **médias** obtidas para o arremesso de 1, 2, 3, 5, 10 e 20 dados.

## Observações

- 1 Em muitos casos de interesse prático, se  $n \geq 30$ , a aproximação normal será satisfatória, independentemente da forma da população;
- 2 Se  $n < 30$ , o teorema do limite central funcionará, se a distribuição da população não for muito diferente da normal.

Quando está presente uma considerável assimetria, de acordo com [Montgomery e Runger(2016)], a aplicação do teorema do limite central para a descrição da distribuição amostral deve ser interpretada com cuidado!

Uma regra empírica que tem sido usada com sucesso em pesquisas por amostragem, onde é comum tal comportamento da variável  $(\beta_3)$ , é que

$$n > 25.(\beta_3)^2.$$

### Exemplo 1 - [Cancho(2010)]

Suponha que na produção em série de um artigo, a massa é uma variável aleatória com uma média de 950 g e uma variância de  $1600 \text{ g}^2$ . Seleccionam-se aleatoriamente e com reposição 36 artigos. Calcular a probabilidade da média amostral ser maior que 965 g.

**Exemplo 2** - [Montgomery e Runger(2016)]

Suponha que uma variável aleatória  $X$  tenha uma distribuição contínua uniforme

$$f(x) = \begin{cases} 1/2, & \text{se } 4 \leq x \leq 6 \\ 0, & \text{caso contrário.} \end{cases}$$

Encontre a distribuição da média de uma amostra aleatória de tamanho  $n = 40$ .



# Distribuição da diferença de duas médias amostrais

Seja  $X_1, X_2, \dots, X_{n_1}$  uma amostra aleatória de tamanho  $n_1$  de uma população com característica  $X$  que tem **distribuição normal** com média  $\mu_1$  e variância  $\sigma_1^2$ .

Seja também,  $Y_1, Y_2, \dots, Y_{n_2}$  outra amostra aleatória de tamanho  $n_2$ , de uma população com a característica  $Y$  que tem **distribuição normal** com média  $\mu_2$  e variância  $\sigma_2^2$ .

Se  $X$  e  $Y$  são independentes, então a diferença amostral  $\bar{X} - \bar{Y}$  tem distribuição normal com média  $\mu_1 - \mu_2$  e variância  $\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}$ . Isto é,

$$Z = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1). \quad (3)$$



## Observação

Se as populações onde foram retiradas as amostras não tiverem distribuição normal, pelo teorema do limite central, segue válido o resultado se os tamanhos amostrais  $n_1$  e  $n_2$  forem suficientemente grandes, isto é  $n_1 \geq 30$  e  $n_2 \geq 30$ .



### Exemplo - [Montgomery e Runger(2016)]

A vida de um componente usado em um motor de uma turbina de um avião é uma variável aleatória, com média de 5000 horas e desvio-padrão de 40 horas. A distribuição da vida é aproximada pela distribuição normal.

O fabricante do motor introduz uma melhoria no processo de fabricação para esse componente, que aumenta a vida média para 5050 horas e diminui o desvio-padrão para 30 horas. Considere novamente a normalidade para essa nova vida.

Suponha que uma amostra aleatória de  $n = 16$  componentes seja selecionada do processo antigo e uma amostra aleatória de  $m = 25$  componentes seja selecionada do processo novo.

Qual é a probabilidade de que a diferença nas duas médias amostrais  $\bar{X}_2 - \bar{X}_1$  seja no mínimo de 25 horas? Considere que o processo antigo e o melhorado possam ser considerados como populações independentes.



# Distribuição amostral de uma proporção amostral

Considere uma população dicotômica, constituída apenas por elementos de dois tipos, isto é, cada elemento pode ser classificado como *sucesso* ou *fracasso*. Suponha que a probabilidade de sucesso seja  $p$  e de fracasso seja  $q = 1 - p$ .

Dessa população retira-se uma amostra aleatória de  $n$  observações,  $X_1, \dots, X_n$ , onde

$$X_i = \begin{cases} 1, & \text{se sucesso} \\ 0, & \text{caso contrário.} \end{cases}$$



Seja a variável aleatória  $Y$  que conta o  $n^o$  de sucessos na amostra. Então:

- ❶  $Y = \sum_{i=1}^n X_i$  tem distribuição Binomial com parâmetros  $n$  e  $p$ .
- ❷ A proporção amostral de sucessos é:  $\hat{p} = \frac{Y}{n} = \sum_{i=1}^n X_i/n = \bar{X}$ . De (1), a distribuição de probabilidade de  $\hat{p}$  é:

$$P(\hat{p} = \frac{y}{n}) = P(\frac{Y}{n} = \frac{y}{n}) = P(Y = y) = \binom{n}{y} p^y (1-p)^{n-y}.$$

E para  $n$  suficientemente grande ( teorema do limite central), a proporção amostral tem distribuição aproximadamente normal com média  $p$  e variância  $\frac{pq}{n}$ . Isto é,

$$\hat{p} \sim N(p, \frac{pq}{n}).$$

### Exemplo - [Cancho(2010)]

Uma empresa tem um número grande de funcionários. A probabilidade de que um empregado selecionado ao acaso, participe de um programa de treinamento é 0,40.

- (a) Se 10 funcionários são escolhidos ao acaso, qual é a probabilidade que proporção de participantes seja
  - (a1) exatamente 60%?
  - (a2) pelo menos 80%?
- (b) suponha que 100 funcionários são escolhidos ao acaso. Qual é a probabilidade de que a proporção amostral de participantes do programa seja maior que 50%?









## Observação

Os resultados acima são válidos também nos seguintes casos:

- 1 Para uma população infinita, qualquer que seja o tipo de amostragem.
- 2 Para população finita, com amostragem com reposição.



Se a amostragem é **sem reposição**, em uma população finita de  $N$  elementos, a distribuição exata de probabilidade  $\hat{p}$  é uma distribuição Hipergeométrica. Isto é,

$$P(\hat{p} = \frac{y}{n}) = \frac{\binom{M}{y} \binom{N-M}{n-y}}{\binom{N}{n}} \quad (4)$$

A variância de  $\hat{p}$  é ajustada através do fator de correção de população finita, isto é,

$$Var(\hat{p}) = \frac{pq}{n} \left( \frac{N-n}{N-1} \right).$$

Se,  $n$  é suficientemente grande, pelo teorema central do limite, a variável aleatória,

$$Z = \frac{\hat{p} - p}{\sqrt{\frac{pq}{n} \left( \frac{N-n}{N-1} \right)}},$$

tem distribuição aproximadamente normal padrão.

### Exemplo - [Cancho(2010)]

Informações anteriores mostram que 10% do lote de peças para uma máquina são defeituosas. Suponha que um lote de 5000 peças foi adquirido. Seleciona-se uma amostra de 400 peças, ao acaso e sem reposição. Qual a probabilidade da amostra ter:

- (a) entre 9% e 10% de peças defeituosas?
- (b) menos de 8% de peças defeituosas?





## Distribuição Qui-quadrado ( $\chi^2$ )

Sejam  $Z_1, Z_2, \dots, Z_k$  variáveis aleatórias distribuídas normalmente e independentes com média  $\mu = 0$  e variância  $\sigma^2 = 1$ . A variável aleatória

$$W = Z_1^2 + Z_2^2 + \dots + Z_k^2 \quad (5)$$

tem distribuição Qui-quadrado com  $k$  graus de liberdade e sua função de densidade é dada por:

$$f(w) = \frac{1}{\Gamma(k/2)2^{k/2}} w^{\frac{k}{2}-1} e^{-\frac{w}{2}}, \quad w > 0 \quad (6)$$

onde  $\Gamma(a)$  é uma função matemática definida

$$\Gamma(a) = \int_0^{\infty} x^{a-1} e^{-x} dx, \quad \text{para } a > 0,$$

chamada de função gama.

Essa função satisfaz às seguintes propriedades:

$$\Gamma(a) = (a-1)\Gamma(a-1)$$


$$\Gamma(a) = (a-1)!, \text{ para } a \text{ inteiro}$$

$$\Gamma(1/2) = \sqrt{\pi}$$

$$\Gamma(1) = 0! = 1$$

O gráfico da distribuição Qui-quadrado para  $k = 2, 3, 5, 10$  e  $15$  graus de liberdade é mostrado na figura a seguir:



Distribuição  $\chi^2_{(k)}$ 

A notação  $W \sim \chi^2_{(k)}$  é usada para indicar que a variável  $W$  tem distribuição Qui-quadrado com  $k$  graus de liberdade.

## Propriedades

Se  $W \sim \chi^2_{(k)}$


- (a)  $E(W) = k$  e  $Var(W) = 2k$ .
- (b) A distribuição é assimétrica direita.
- (c) A medida que aumentam-se os graus de liberdade, torna-se simétrica.

## Uso da tabela Qui-quadrado

Na tabela  $\chi^2_{(k)}$ , tem-se os pontos críticos da distribuição  $W \sim \chi^2_{(k)}$ , denotado por  $\chi^2_{\alpha,k}$  tal que a probabilidade

$$P(W > \chi^2_{\alpha,k}) = \int_{\chi^2_{\alpha,k}}^{\infty} f(w)dw$$



Pontos críticos  $\chi^2_{\alpha,k}$  das distribuições  $\chi^2_{(k)}$ 

A probabilidade

$$P(W > \chi^2_{\alpha,k}) = \int_{\chi^2_{\alpha,k}}^{\infty} f(w)dw = \alpha$$

é representada pela área sombreada da figura.

Para ilustrar o uso da tabela  $\chi^2_{(k)}$ , observe que as áreas  $\alpha$  estão na primeira linha e na primeira coluna estão os graus de liberdade  $k$ . Portanto, o valor de  $\chi^2$  com 10 graus de liberdade e com área (probabilidade) 0,05 à direita é  $\chi^2_{0,05,10} = 18,31$ . Isto é,

$$P(W > \chi^2_{0,05,10}) = P(W > 18,31) = 0,05.$$



**Exemplo 1** - [Cancho(2010)]

Se  $X$  é uma variável aleatória  $\chi^2_{(17)}$ , então obtenha:

- (a)  $P(X \geq 8,67)$ ;
- (b)  $P(X \leq 8,67)$ ;
- (c)  $P(6,41 < X < 27,59)$ ;
- (d) o valor de  $a$  tal que  $P(X < a) = 0,025$ .

**Exemplo 2** - [Cancho(2010)]

Se  $X$  é uma variável aleatória  $\chi^2_{(4)}$ , então obtenha  $P(X \geq 7,932)$ ;





## Propriedade reprodutiva

Se  $W_1, W_2, \dots, W_n$  são variáveis aleatórias independentes distribuídas cada uma com distribuição Qui-quadrado com  $k_1, k_2, \dots, k_n$  graus de liberdade respectivamente, então, a variável

$$W = W_1 + W_2 + \dots + W_n$$

tem distribuição Qui-quadrado com  $k = \sum_{i=1}^n k_i$  graus de liberdade

## Exemplo

Se  $W_1, W_2$  e  $W_3$  são variáveis aleatórias independentes com distribuição Qui-quadrado respectivamente com 4, 7 e 9 graus de liberdade respectivamente, então  $W = W_1 + W_2 + W_3 \sim \chi^2_{(20)}$ .



# Distribuição $t$ -Student

Sejam  $Z$  e  $W$  duas variáveis independentes com distribuição normal padrão e Qui-quadrado com  $k$  graus de liberdade, respectivamente. A variável aleatória,


$$T = \frac{Z}{\sqrt{\frac{W}{k}}}$$

tem distribuição  $t$ -Student com  $k$  graus de liberdade. A função de densidade de probabilidade é dado por:

$$f(t) = \frac{\Gamma(\frac{k+1}{2})}{(k\pi)^{1/2}\Gamma(\frac{k}{2})} \left(1 + \frac{t^2}{k}\right)^{-(k+1)/2}$$

A notação  $T \sim t(k)$  é usada para indicar que a variável  $T$  tem distribuição  $t$ -Student com  $k$  graus de liberdade.

Na figura abaixo é apresentado o gráfico da função de densidade de probabilidade, para  $k = 1, 2, 5$  e  $10$  graus de liberdade.



**Propriedades** Se  $T \sim t_{(k)}$ .

(a)

$$E(T) = 0$$

$$Var(T) = \frac{k}{k-2}, \quad k > 2$$

(b) A distribuição é simétrica em torno de sua média.


(c) Se  $k \rightarrow \infty$ ,  $T \sim N(0, 1)$ .





## Uso da tabela $t$ -Student

A tabela  $t$ -Student proporciona os pontos críticos da distribuição  $t$ -Student. Seja  $t_{\alpha,k}$  o valor da variável aleatória  $T$  com  $k$  graus de liberdade para o qual tem-se uma área (probabilidade)  $\alpha$ . Portanto,  $t_{\alpha,k}$  é um ponto crítico na cauda superior da distribuição  $t$ -Student com  $k$  graus de liberdade. Este ponto crítico aparece na figura abaixo.



A probabilidade

$$P(T > t_{\alpha,k}) = \int_{t_{\alpha,k}}^{\infty} f(t)dt = \alpha$$

é representada pela área sombreada da figura.

Na tabela  $t$ -Student, os valores de  $\alpha$  encontram-se na primeira linha da tabela, enquanto os graus de liberdade aparecem na primeira coluna da parte esquerda. Para ilustrar o uso da tabela, observe que o valor de  $t$ -Student com 10 graus de liberdade que tem área de 0,05 à direita é  $t_{0,05,10}$ . Isto é,

$$P(T > t_{0,05,10}) = P(T > 1,812) = 0,05$$



Como, a distribuição  $t$ -Student é simétrica em relação a zero (média), tem-se que  $t_{1-\alpha,k} = -t_{\alpha,k}$ . Isto é, o valor da variável  $T$  que corresponde a uma área igual  $(1-\alpha)$  à direita (e, portanto, uma área de  $\alpha$  à esquerda) é igual ao negativo do valor de  $T$ , que tem área  $\alpha$  na cauda direita da distribuição. Em consequência,  $t_{0,95,10} = -t_{0,05,10} = -1,812$ .



**Exemplo** - [Cancho(2010)]

Seja  $T$  uma variável aleatória com distribuição  $t$ -Student com 12 graus de liberdade. Determine:

(a)  $P(T > -1,356)$

(b)  $P(0,695 < T < 2,179)$

(c)  $P(-2,179 < T < 2)$

(d)  $P(-1,782 < T < 1,782)$

# Distribuição F-Snedecor

Seja  $W_1$  uma variável aleatória com distribuição Qui-quadrado com  $k_1$  graus de liberdade e  $W_2$  outra variável aleatória com distribuição Qui-quadrado com  $k_2$  graus de liberdade. Se  $W_1$  e  $W_2$  são independentes, a variável aleatória

$$F = \frac{\frac{W_1}{k_1}}{\frac{W_2}{k_2}}$$

segue uma distribuição F-Snedecor com graus de liberdade:  $k_1$  (numerador) e  $k_2$  (denominador). A função de densidade de probabilidade é dada por:

$$h(f) = \frac{\Gamma(\frac{k_1+k_2}{2})}{\Gamma(k_1/2)\Gamma(k_2/2)} \frac{(\frac{k_1}{k_2})^{\frac{k_1}{2}} f^{\frac{k_1}{2}-1}}{(1 + \frac{k_1}{k_2} f)^{\frac{k_1+k_2}{2}}}, \quad f > 0$$



A notação  $F \sim F(k_1, k_2)$  indica que a variável aleatória  $F$  tem distribuição F-Snedecor, com graus de liberdade  $k_1$  e  $k_2$ .

## Propriedades

Se  $F \sim F(k_1, k_2)$  então

- ❶ A distribuição é assimétrica direita.
- ❷ A média e variância são respectivamente

$$\mu = \frac{k_2}{k_2 - 2}, \quad k_2 > 2 \quad e \quad \sigma^2 = \frac{2k_2^2(k_1 + k_2 - 2)}{k_1(k_2 - 2)^2(k_2 - 4)}, \quad k_2 > 4$$




## Uso da tabela F-Snedecor

Os pontos críticos da distribuição  $F$ -Snedecor são apresentados na tabela F. Seja  $f_{\alpha,k_1,k_2}$  o ponto crítico da distribuição  $F$  com  $k_1$  graus de liberdade no numerador e  $k_2$  graus de liberdade no denominador, tal que a probabilidade de que variável aleatória  $F$  seja maior que este valor é

$$P(F > f_{\alpha,k_1,k_2}) = \int_{f_{\alpha,k_1,k_2}}^{\infty} h(f)df = \alpha$$

Isto é ilustrado na figura abaixo.



Por exemplo se  $k_1 = 5$  e  $k_2 = 10$ , então da tabela F tem-se:

$$P(F > f_{0,05;5;10}) = P(F(5, 10) > 3,33) = 0,05.$$

Isso é o ponto crítico do 5% superior de  $F(5, 10)$  é  $f_{0,05;5;10} = 3,33$ .





A tabela F contém somente pontos críticos na cauda superior (valores de  $f_{\alpha,k_1,k_2}$ , para  $\alpha \leq 0,25$ ) da distribuição F. Os pontos críticos na cauda inferior  $f_{1-\alpha,k_1,k_2}$  podem ser obtidos da seguinte forma:

$$f_{1-\alpha,k_1,k_2} = \frac{1}{f_{\alpha,k_2,k_1}}.$$

Por exemplo, para determinar o ponto crítico na cauda inferior  $f_{0,95;5;10}$  observe que:

$$f_{0,95;5;10} = \frac{1}{f_{0,05;10;5}} = \frac{1}{4,74} = 0,211.$$



Seja  $Y$  uma variável aleatória que segue uma distribuição  $F$ -Snedecor.

(a) Se  $Y \sim F(8, 12)$  obtenha:

❶  $P(Y > 2,85);$

❷  $P(2,85 < Y < 4,50);$

❸  $y_1$  se  $P(y_1 < Y < 2,85) = 0,94$

(b) Se  $Y \sim F(45, 24)$ , achar  $y_1$  tal que,  $P(Y \leq y_1) = 0,95$







Cancho, V., 2010. Notas de aulas sobre noções de estatística e probabilidade - São Paulo: USP.



Montgomery, D., Runger, G., 2016. Estatística Aplicada e Probabilidade para Engenheiros. Rio de Janeiro: LTC.

